


人工智能引论

18. 知识图谱

授课教师 张辉帅

2026年05月30日



- 知识图谱的概念
- 知识图谱的研究进展
- 知识图谱的应用场景
- 知识图谱的构建与应用

目录


- **知识图谱的概念**
- **知识图谱的研究进展**
- **知识图谱的应用场景**
- **知识图谱的构建与应用**

知识的概念




北京大学
PEKING UNIVERSITY

人类通过认识世界积累**知识**，并通过语言来描述、记录和传承关于世界的**知识**。具有**获取、表示和处理知识**的能力是人类心智区别于其它物种心智的最本质特征，也是人脑智能的最本质特征。




语言是知识的自然描述方式和表达载体。人脑能够从文本获取和学习知识，机器脑也应该具备从文本中抽取知识的能力，从而更好地服务于人类的需求。




知识图谱的概念

知识图谱(Knowledge Graph, KG)旨在利用**图结构**建模、识别和推断**事物之间的复杂关联关系**和**沉淀领域知识**，是实现**认知智能**的重要基石，已经被广泛应用于搜索引擎、智能问答、语言语义理解、大数据决策分析、智能物联等众多领域。



图是一种较复杂的数据结构，由**顶点集**和**边集**组成。图结构可以方便地研究数据元素之间的**多对多**关系。




知识图谱的概念




北京大学
PEKING UNIVERSITY

- **知识图谱**(Knowledge Graph)本质上是一种大规模**语义网络**(Semantic Network)
 - **实体** (entity): 表示客观存在的事物或抽象概念
 - **C罗、葡萄牙、皇家马德里**
 - **关系**(relationships): 表示两个实体（分为**主实体**和**客实体**）之间的某种关联
 - **获得奖项、举办单位、效力球队**



知识图谱的概念

通常情况下，知识图谱以**三元组**的形式保存，即将知识图谱拆分成**<节点，边，节点>**，也称**<实体，关系，实体>**。其中，实体为特定的实例对象，关系为实体间抽象的关联，例如<小明，喜欢，猫>。




目录

- 知识图谱的概念
- 知识图谱的研究进展
- 知识图谱的应用场景
- 知识图谱的构建与应用


知识图谱的研究概况

知识图谱简史：**1959-2012**年间，知识图谱的相关概念逐步被确立。**2012年**Google正式提出知识图谱的概念。



知识图谱的研究概况

知识图谱是一种语义网络。语义网络（Semantic Network）是美国心理语言学家奎廉（M.R. Quilian）于1956年提出的，用来描述人的联系记忆。



语义网络示例


知识图谱起源于**符号主义**(Symbolism), 又称为**逻辑主义**(logicism)、**心理学派**(Psychologism)或**计算机学派**(Computerism)。

符号主义的主要观点包括:

1. 认知即计算
2. 知识是信息的一种形式,是构成智能的基础
3. 知识表示、知识推理、知识运用是人工智能的核心


知识图谱的研究概况

知识工程(Knowledge Engineering)是知识图谱的重要应用场景之一。知识工程是以知识为处理对象，研究知识系统的知识表示、处理和应用的方法与开发工具的学科。



知识图谱的研究概况


传统知识工程在**规则明确**、**边界清晰**、**应用封闭**的应用场景取得了巨大成功。



知识工程代表性系统

知识图谱的研究概况

- 专家系统(Expert Systems)
- 起源于20世纪60年代中后期
- 知识工程(Knowledge Engineering)的代表性技术之一
- 产生了巨大的社会效益和经济效益



但是，传统的**知识工程**严重依赖专家和人的干预，常常面临知识获取困难和知识应用困难的难题。

知识难获取问题


- 隐性知识、过程知识等难以表达
- 领域知识的形式化表达较为困难
- 专家知识不可避免地存在主观性
- 不同专家之间知识可能存在不一致性
- 知识表达难以完备，缺漏是常态

知识难应用问题

- 应用易于超出预先设定的知识边界
- 很多应用需要常识的支撑
- 难以处理异常情况
- 难以处理不确定性推理
- 知识更新困难

知识图谱的研究概况


互联网时代的大规模开放性应用需要全新的知识表示，在知识工程迈入大数据时代的背景下，谷歌提出了**知识图谱**的概念。



知识图谱的研究概况

知识图谱在大数据背景下的特点： **更多实体信息**

KGs	# of Entities/Concepts	# of Relations
YAGO	10 Million	120 Million
DBpedia	28 Million	9.5 Billion
Probase	2.7 Million	70 Billion
BabelNet	14 Million	5 Billion
CN-DBpedia	17 Million	200 Million



Existing Taxonomies	Number of Concepts
Freebase [5]	1,450
WordNet [13]	25,229
WikiTaxonomy [26]	111,654
YAGO [35]	352,297
DBpedia [1]	259
ResearchCyc [18]	≈ 120,000
KnowItAll [12]	N/A
TextRunner [2]	N/A
OMCS [31]	N/A
NELL [7]	123
Probase	2,653,872


知识图谱的研究概况



北京大学
PEKING UNIVERSITY

知识图谱在大数据背景下的特点：更加丰富的语义关系

KGs	# of Relations
DBpedia	1,650
YAGO1	14
YAGO3	74
CN-DBpedia	100 Thousands




知识图谱的研究概况



北京大学
PEKING UNIVERSITY


知识图谱在大数据背景下的特点：**更高的质量**



网络中广泛的数据包含对真实世界更加完备的解读和描述

*图片来源: <https://www.google.com/url?sa=i&url=https%3A%2F%2Fwww.liveai.eu%2Fknowledge-graph-and-graph-neural-networks%2F&psig=AOvVaw2cWxP-LrOvHY47zsQcrOfz&ust=1684134510230000&source=images&cd=yfe&ved=0CBEQjRxqFwoTCLCszI6g9P4CFQAAAAAdAAAAABAF>


知识图谱在大数据背景下的特点：**友好的结构**



结构化的存储方式便于索引和推理


知识图谱的研究概况

知识图谱的研究方向：**知识抽取、知识表示、知识图谱的应用、时序知识图谱、多模态知识图谱**等是当前最重要的研究内容。



知识图谱的研究概况

多模态知识图谱：传统知识图谱主要集中研究**文本数据库**的实体和关系，而多模态知识图谱则在传统知识图谱的基础上，构建了多种模态（例如**图片**、**视频**、**音频**等）下的实体，以及多种模态实体间的多模态语义关系。



知识图谱的研究概况

典型知识图谱项目：Freebase

完全免费并允许商业化的开放许可协议



Freebase是一个由元数据组成的大型合作知识库，内容主要来自其社区成员的贡献。它整合了许多网上的资源，包括部分私人wiki站点中的内容。Freebase致力于打造一个允许全球所有人（和机器）快捷访问的资源库。它由美国软件公司MetaWeb开发并于2007年3月公开运营。2010年7月16日被谷歌收购。


知识图谱的研究概况



北京大学
PEKING UNIVERSITY

典型知识图谱项目： **WikiData** (<https://www.wikidata.org/>)

目标是构建全世界最大的免费知识库，采用CC0完全自由许可协议



WikiData的目标是构建一个免费开放、多语言、任何人或机器都可以编辑修改的大规模链接知识库。WikiData由维基百科于2012年启动，早期得到微软联合创始人Paul Allen、Gordon Betty Moore基金会以及Google的联合资助。截止2016年，WikiData已经包含超过2470多万个知识条目。

知识图谱的研究概况



北京大学
PEKING UNIVERSITY

典型知识图谱项目：Schema (<https://schema.org>)

Semantic Markup: 在网页、邮件、应用程序中嵌入语义数据

```
<p>Big (1988) is a fantasy comedy movie starting Tom Hanks and directed by Penny Marshall.</p>
```

RDFa, JSON-LD, HTML5 Microdata

```
<div itemscope itemtype="http://schema.org/Movie"><p>  
<span itemprop="name">Big </span> (1988) is a  
<span itemprop="genre">fantasy comedy</span> movie starting  
<span itemprop="actor" itemscope itemtype="http://schema.org/Person">  
<span itemprop="name">Tom Hanks</span></span> and directed by  
<span itemprop="director" itemscope itemtype="http://schema.org/person">  
<span itemprop="name">Penny Marshall</span></span>.</p></div>
```

搜索引擎优化



谷歌2015年12月推出的Customizable Knowledge Graph, 允许各网站基于Schema.org, 以RDFa, JSON-LD, HTML Microdata等方式在网页、邮件等数据源中嵌入语义化数据, 支持个人和企业定制自己的知识图谱信息, 全球约有1.2亿的网站, 超过30% 的网页已经嵌入有Schema.org的语义数据。

知识图谱的研究概况

中文领域开放知识图谱: www.openkg.cn



知识图谱的研究概况

中文领域开放知识图谱: <https://www.ownthink.com/>



- 知识图谱的概念
- 知识图谱的研究进展
- 知识图谱的应用场景
- 知识图谱的构建与应用

知识图谱的应用场景



北京大学
PEKING UNIVERSITY

辅助搜索—语义搜索



知识图谱的应用场景

辅助问答交互—知识问答

电子设备智能化：通过知识库提供领域知识




DUER OS
Conversational AI OS for everyone and everywhere




知识图谱的应用场景

辅助推荐系统

将知识图谱引入到推荐系统中，有利于挖掘更深层次的用户兴趣和实现更加个性化的推荐。



Collaborative Knowledge Base Embedding for Recommender Systems. KDD 2016 Microsoft Research





阿飞正传，因为他们有相同的**主演**；
末代皇帝，因为他们有相同的**题材**；
搜索，因为他们有相同的**导演**；
.....

知识图谱的应用场景



北京大学
PEKING UNIVERSITY


辅助大数据分析



- ▶ 语义集成: Dynamic Ontology
- ▶ 语义搜索: 围绕Ontology来搜索发现结果和关系;
- ▶ 知识管理: 所有的知识是有权限控制的;
- ▶ 协作: 知识可以在不同的用户之间共享, 协同工作;
- ▶ 算法引擎: 对于通用领域问题, 提供了通用算法来发现趋势

辅助视觉理解

知识图谱在CV领域有广泛的应用，将视觉识别出的对象链接到外源的知识图谱，可用来辅助图像语义关系抽取和视觉语义的深入理解等。




知识图谱的应用场景



北京大学
PEKING UNIVERSITY

辅助判案



目录

- 知识图谱的概念
- 知识图谱的研究进展
- 知识图谱的应用场景
- 知识图谱的构建与应用

知识图谱的构建和应用


关键步骤：知识抽取、知识表示、知识推理

文本

北京大学创办于1898年，初名京师大学堂，是中国第一所国立综合性大学，也是当时中国最高教育行政机关。辛亥革命后，于1912年改为现名。



...

知识
抽取




	发展定位	世界一流大学
	类型	综合
	所属地区	中国北京
	简称	北大 (PKU)
	知名校友	朱自清
	知名校友	李克强

知识
表示




知识
推理



北京大学有多少年的历史？

北京大学已经有125年历史。

知识抽取(Knowledge Extraction)是构建知识图谱的首个环节，其目的在于从不同来源、不同结构的数据中进行知识提取，形成知识并存入到知识图谱。




在知识图谱中，知识的载体是实体、关系

知识抽取的概念




北京大学
PEKING UNIVERSITY

- **实体(Entity)**一般是名词，表示是人、事、物等具体对象，比如：员工、公司等。
- **关系(Relation)**指实体间的联系，如创作、购买、喜欢等。



实体抽取、**关系抽取**和**事件抽取**是知识抽取的核心内容。其中，事件是指发生的事情，通常具有时间、地点、参与者等要素，事件的发生通常是因为动作的发生或者系统状态的改变，如结婚、解聘等。



知识抽取——实体抽取

实体抽取：又称**命名实体识别**（Named Entities Recognition, NER），实体抽取旨在抽取文本中的原子信息元素，通常包含**人名**、**组织/机构名**、**地理位置**、**时间/日期**等标签。


北京大学创办于1898年，初名京师大学堂，是中国第一所国立综合性大学。

机构 时间 国家 类型

方法1：基于人工设计的模板和规则匹配实体词


- 将文本与规则进行匹配来识别出命名实体
 - “***认为”、“***提出”
 - “坐落于***”、“战胜***”
- 优点
 - 人工设计的规则准确性高
 - 可控性强，可针对性设计模板与规则
- 缺点
 - 需要大量的语言学知识
 - 需要谨慎处理规则之间的冲突问题
 - 构建规则的过程费时费力、可移植性差

方法2：基于序列标注的机器学习方法




主流的机器学习模型


隐马尔科夫链



循环神经网络



Transformer



知识抽取——关系抽取


关系抽取 (Relation Extraction) 是指从文本中抽取两个或者多个实体之间的语义关系，作为从文本获取知识图谱三元组的主要技术手段，通常被用于知识图谱的补全。

北京大学创办于1898年，初名京师大学堂，是中国第一所国立综合性大学。



(北京大学, 创办于, 1898年), (北京大学, 初名, 京师大学堂)
(北京大学, 位于, 中国), (北京大学, 属于, 国立综合性大学)

关系抽取方法概览：



知识抽取——关系抽取

方法1：基于模板的方法

基于触发词匹配的关系抽取

河南 省会 郑州
湖北 省会 武汉

→ 省会 (X,Y)
触发词：省会

中国 首都 北京
美国 首都 华盛顿

→ 首都 (X,Y)
触发词：首都

→ 辖属关系 (X, Y)
触发词：省会，首都

注：两个实体之间可以存在多种关系

方法2：基于监督学习的关系抽取

典型流程

- 预先定义好关系类别
- 人工标注数据
- 设计特征表示
- 选择分类方法
- 评估结果

实例：特征函数+最大熵模型

目标：已知 X 输入数据，求解令熵 H 最大的条件概率 $P(y|x)$

$$H(P) = - \sum_{x,y} \bar{P}(x) P(y|x) \log P(y|x)$$

约束条件

$$E_{\bar{P}}(f_i) - E_P(f_i) = 0 \quad (i = 1, 2, \dots, M)$$

$$\sum_y P(y|x) = 1$$

f_i 为文本特征

知识抽取——事件抽取

事件(event)是发生在某个特定的时间点或时间段、某个特定的地域范围内，由一个或者多个角色参与的一个或者多个动作组成的事情或者状态的改变。

- 事件分为不同的类型，如体育竞技、恐怖袭击、天气骤变等，
- 每种类型的事件可包含不同的实例，例如奥运会中不同场次的比赛为“体育竞技”事件的不同实例



体育竞技



袭击



天气变化

知识抽取——事件抽取


事件抽取(Event Extraction)是指从无结构文本中自动抽取结构化事件知识（即事件实例），包含事件发现和分类、事件要素提取两个过程，其中事件要素为事件所涉及的人/组织，时间，地点等。




事件发现和分类

事件触发	触发词	成立
	事件类型	“设立单位”事件
事件要素	要素：机构	北京大学
	要素：时间	2021年12月
	要素：单位	智能学院

事件要素的提取



知识表示 (Knowledge Representation, KR) 就是用易于计算机处理的方式来描述人脑的知识，并支持通过符号之间的运算来模拟人脑的推理过程。



一阶谓词逻辑 (First Order Predicate Logic) 也称经典逻辑，是一种基于数理逻辑的知识表示方法，是到目前为止能够表达人类思维活动规律的一种最精准形式语言。它与人类的自然语言比较接近，又可方便存储到计算机中去，并被计算机进行精确处理。

例：北京大学五月举办校庆

$(\forall \text{Month})(\text{May}(\text{Month}) \rightarrow \text{Hold}(\text{PKU}, \text{Anniversary}))$

一阶谓词逻辑基本理论

一、命题与逻辑联结词

1.命题(Propositional)是具有真假意义的陈述句。

命题若是简单的陈述句，不能分解成更简单的句子，我们称这样的命题为**简单命题**或**原子命题**(Atomic Proposition)。可以用英文字母 $P, Q, R, \dots$ 或是带有下标的大写英文字母 P_i 等表示简单命题，将命题用合适的符号表示，称为命题符号化(Symbolization)。

□ 对于简单命题来说，如果它的真值是确定的，又可被称为**命题常项**或**命题常元**(Proposition Constant)。

□ 真值可以变化的简单陈述句称为**命题变项**或**命题变元**(Propositional Variable)。

- 北京大学位于上海 is 假命题
- 现在是上课时间 is 命题变元

一阶谓词逻辑基本理论

一、命题与逻辑联结词

2. 逻辑联结词用于将多个原子命题组合成复合命题

- (1) $\neg$: 否定联结词, 当命题 P 为真时, 则 $\neg P$ 为假, 反之为真。
- (2) $\vee$: 析取联结词, 它表示两个命题存在“或”的关系。
- (3) $\wedge$: 合取联结词, 它表示两个命题之间具有“与”关系。
- (4) $\rightarrow$: 蕴含、“单条件”, $P \rightarrow Q$ 表示“如果 P , 则 Q ”。其中 P 为前件, Q 为后件。
- (5) $\leftrightarrow$: 等价、“双条件”, $P \leftrightarrow Q$ 表示“ P 当且仅当 Q ”。

➤ 北京大学不在上海

$\neg \text{Shanghai(PKU)}$

➤ 现在是上课时间或下课时间

$\text{Class(present)} \vee \text{Break(present)}$

一阶谓词逻辑基本理论

一、命题与逻辑联结词

3. 复合命题与原子命题的真值关系表 (T表示真, F表示假)

P	Q	$\neg P$	$P \wedge Q$	$P \vee Q$	$P \rightarrow Q$	$P \leftrightarrow Q$
T	T	F	T	T	T	T
T	F	F	F	T	F	F
F	T	T	F	T	T	F
F	F	T	F	F	T	T

一阶谓词逻辑基本理论

二、个体词、谓词与函数

1. 个体词(Individual Word) 表示领域内可以独立存在的具体或抽象的客观物体。(对应于知识图谱中实体的概念)

在谓词逻辑中，个体是常量也可以是变量。

个体常量(Individual Constant): 表示具体的或者特定的个体。

个体变量(Individual Variable): 表示抽象的或者泛指个体。

个体域 (论域) : 个体变量的值域。个体域可以是有限的也可以是无限制的。

示例:

➤ **北京大学有智能学院 (北京大学、智能学院为个体词)**

一阶谓词逻辑基本理论

二、个体词、谓词与函数

2. 谓词(predicate)是用来刻画个体性质以及个体之间相互关系的词。(对应于知识图谱中关系的概念)

示例:

➤ **北京大学在北方**

➤ 其中, 北京大学(PKU)是个体变量, “在北方” 是谓词, 将其记为 North , 则该命题符号化为 **North(PKU)**

3. n 元谓词是含有 n 个个体符号的谓词 $P(x_1, x_2, \dots, x_n)$, 它表示 $x_1, x_2, \dots, x_n$ 具有关系 P 。

示例:

➤ **北京大学在中国的北部**

➤ 命题符号化为 **North(PKU, China)**

一阶谓词逻辑基本理论

二、个体词、谓词与函数

4. 函数又称函数词，是从若干个个体到某个个体的映射。

示例：

➤ Principal(PKU)：北京大学校长（函数用于描述新的实体——校长）

5. 谓词和函数的区别：

- 谓词描述属性和关系，可判断真假
- 函数用已知实体描述新的实体，没有真值的概念
- 在谓词逻辑中，函数本身不能单独使用，它必须嵌入到谓词中。

一阶谓词逻辑基本理论

二、个体词、谓词与函数

6. 量词，用来对个体的数量进行约束。

- 全称量词 $\forall$ ：表示“对所有的个体，都...”

例子：今天下雨 $\text{Rain}(\text{Today})$

每天都下雨 $\forall x \text{Rain}(x)$

$\forall x P(x)$ 为真 $\Leftrightarrow$ 对个体域内所有个体 x 都有 $P(x)$ 为真

- 存在量词 $\exists$ ：表示“存在某个个体，使得...”

例子：张三缺席 $\text{Absence}(\text{John Smith})$

有人缺席 $\exists x \text{Absence}(x)$

$\exists x P(x)$ 为真 $\Leftrightarrow$ 个体域内存在至少一个个体 x ，使得 $P(x)$ 为真

一阶谓词逻辑既可以表示事物的状态、属性、概念等事实性知识，也可以表示事物间具有因果关系的规则性知识。

用谓词逻辑表示知识的一般步骤：

- 定义谓词及个体，确定每个谓词及个体的确切含义
- 根据所要表达的事物或概念，为每个谓词中的变量赋予特定的值
- 根据所要表达的知识的语义，用适当的逻辑联结词将各个谓词连接起来形成谓词公式

例：北京大学五月举办校庆

实体：北京大学 实体：校庆 谓词：五月 谓词：举办

$(\forall \text{Month})(\text{May}(\text{Month}) \rightarrow \text{Hold}(\text{PKU}, \text{Anniversary}))$

例1：北京是一个美丽的城市。

BeautifulCity(Beijing)

北京: Beijing, 是美丽的城市: BeautifulCity()

例2：北京处于上海和哈尔滨中间。

Locate(x, y, z)

北京: x, 上海: y, 哈尔滨: z, ...在...和...中间: Locate()

例3：有些游客不喜欢看表演。

$(\exists x)(\neg \text{Like}(x, y))$

游客: x, 表演: y, 喜欢: Like()

例4：小明的爸爸是一个猎人。

Hunter(Father(x))

Father(x)是函数表示x的爸爸, Hunter()是谓词

例5：如果一个数能被4整除, 则它能被2整除。

$(\forall x)(D(x, 4) \rightarrow D(x, 2))$

数x能被n整除: $D(x, n)$

一阶谓词逻辑表示法的优缺点


优点

- **精确性**：可以较准确地表示知识并支持精确推理
- **通用性**：拥有通用的逻辑演算方法和推理规则
- **自然性**：是一种接近于人类自然语言的形式语言系统
- **模块化**：各条知识相对独立，它们之间不直接发生联系，便于知识的添加、删除和修改

缺点

- **表示能力差**：只能表示确定性知识，不能表示非确定性知识、过程性知识和启发式知识
- **管理困难**：缺乏知识的组织原则，知识库管理困难
- **效率低**：把推理演算与知识含义分开，往往使推理过程冗长、降低了系统效率
- 仿照人的思维逻辑设计的表示方式，对于机器可能**不是最优**的

产生式表示法(Production Representation)又称**产生式规则表示法**。产生式表示预先定义的规则，依照规则序列对问题进行描述的思维过程称为**产生式系统**(Production System)。



产生式系统的组成

- 规则库为人工定义的客观规则，例如**大学是高等学校**
- 综合数据库包含事实，例如**北京大学是一所大学**
- 推理机负责根据数据库和规则获得结论，例如**事实**(北京大学是一所大学)+**规则**(大学是高等学校)→**结论**(北京大学是高等学校)

框架(Frame)是描述对象（事物，事件或概念）属性的一种数据结构。**框架网络**(Frame Network)是由不同的框架通过属性之间的关系而建立起来的联系，从而形成的网络结构。框架网络能够充分表达相关对象之间的各种关系。

例1：教师的类框架

框架名：<教师>

年龄：(1~120)


工作：范围：（教学，科研）

缺省：教学

性别：（男，女）

学历：（学士，硕士，博士）


类型：（<小学教师>， <中学教师>， <大学教师>）



向量表示法


逻辑表示法、产生式表示法、框架表示法均用人工设置的**离散符号**来表示本体、关系等知识，因而称为**符号表示法**。在网络数据大爆炸的时代，手工定义的符号和推理规则难以存储和管理海量的知识。知识的**向量化表示**具有更丰富的表达空间，并且能够依托神经网络框架实现自动更新，逐渐应用在大规模知识图谱中。

基于离散符号的知识表示



显式知识、强逻辑约束、可解释性强、推理不易扩展、
表示空间小

基于连续向量的知识表示




隐式知识、弱逻辑约束、不易解释、可对接神经网络、
表示空间大

向量表示法——模型与训练

基于平移(Translation)的模型^[1]:

在自然语言模型中, 属性差别相近的词在词向量空间呈现平移不变性, 比如 $\overrightarrow{King}$ 和 $\overrightarrow{Queen}$ 之间的向量差与 $\overrightarrow{Man}$ 和 $\overrightarrow{Woman}$ 之间的向量差接近。


受到该现象的启发, 一系列基于关系向量不变性约束的方法被提出: 具有相同关系的实体, 在实体空间的向量差应相同, 该向量差即为关系的向量化表达。




$$\overrightarrow{King} - \overrightarrow{Queen} \approx \overrightarrow{Man} - \overrightarrow{Woman}$$

向量表示法——模型与训练


基于平移(Translation)的模型变体^[1]




(a) TransE




(b) TransH




(c) TransR




(d) TransD



(e) TransA




(f) KG2E




(g) TransG

- 知识图谱推理将机器推理（Machine Reasoning）简化为事实预测或关系推理。
- 许多现实生活中的问题（链接预测、因果推理、基于知识图谱的问答、推荐等）都可以表述为知识图谱推理。



面向知识图谱的推理主要围绕**关系推理**展开，即基于图谱中已有的事实或关系推断出未知的事实或关系。一般着重考察**实体**、**关系**和**图谱结构**三个方面的特征信息。

具体来说，知识图谱推理主要能够辅助推理出新的**事实**、新的**关系**、新的**公理**以及新的**规则**等。



推理规则:逻辑等价式

P	Q	$\neg P$	$P \wedge Q$	$P \vee Q$	$P \rightarrow Q$	$P \leftrightarrow Q$
T	T	F	T	T	T	T
T	F	F	F	T	F	F
F	T	T	F	T	T	F
F	F	T	F	F	T	T

其中:

① $P \rightarrow Q$ 等价于 $\neg P \vee Q$;

③ $\neg(P \vee Q)$ 等价于 $\neg P \wedge \neg Q$;

⑤ $R \wedge (P \vee Q)$ 等价于 $(R \wedge P) \vee (R \wedge Q)$;

② $P \leftrightarrow Q$ 等价于 $(P \wedge Q) \vee (\neg P \wedge \neg Q)$

④ $\neg(P \wedge Q)$ 等价于 $\neg P \vee \neg Q$

⑤ $R \vee (P \wedge Q)$ 等价于 $(R \vee P) \wedge (R \vee Q)$

推理规则:量词运算

取反 $\neg \forall x P(x) \equiv \exists x \neg P(x) \quad \neg \exists x P(x) \equiv \forall x \neg P(x)$

分配律 $\forall x (P(x) \wedge Q(x)) \equiv \forall x P(x) \wedge \forall x Q(x)$


$$\exists x (P(x) \vee Q(x)) \equiv \exists x P(x) \vee \exists x Q(x)$$

量词顺序 $\forall x \forall y P(x, y) \equiv \forall y \forall x P(x, y)$

$$\exists x \exists y P(x, y) \equiv \exists y \exists x P(x, y)$$

一般来说 $\exists x \forall y P(x, y) \not\equiv \forall y \exists x P(x, y)$

一阶谓词逻辑的**形式演绎推理**:



- 形式演绎推理：
 - **自然演绎推理：**
 - 从一组已知为真的事实出发，直接运用经典逻辑中的推理规则推出结论的过程称为自然演绎推理。
 - **归结演绎推理：**
 - 归结演绎推理是一种基于鲁宾逊(Robinson)归结原理的机器推理技术，核心思想是将问题转化成多个子句，然后通过相互消解进行简化，最终推理出目标形式。归结原理的出现，被认为是自动推理，特别是定理机器证明领域的重大突破。从理论上解决了定理证明问题。

自然演绎推理示例

设有前提：

- (1) 北京大学**在且只在**青年节举办校庆；
- (2) 北京大学今天举办校庆。

问：今天是青年节吗？

解：令 $\text{Youth}(t)$ ：日期 t 是青年节； $\text{Anniversary}(X, t)$ ： X 于 t 日举办校庆；
 pku ：北京大学， a ：今天的。

则上面的两个命题可用谓词公式表示为：

- (1) $\forall t(\text{Youth}(t) \leftrightarrow \text{Anniversary}(\text{pku}, t))$
- (2) $\text{Anniversary}(\text{pku}, a)$

故 $\text{Youth}(a)$ ，则今天是青年节 (✓)

自然演绎推理示例

设有前提：

- (1) 北京大学在青年节举办校庆；
- (2) 北京大学今天举办校庆。

问：今天是青年节吗？

解：令 $\text{Youth}(t)$ ：日期 t 是青年节； $\text{Anniversary}(X, t)$ ： X 于 t 日举办校庆；
 pku ：北京大学， a ：今天的。

则上面的两个命题可用谓词公式表示为：

- (1) $\forall t(\text{Youth}(t) \rightarrow \text{Anniversary}(\text{pku}, t))$
- (2) $\text{Anniversary}(\text{pku}, a)$

能否推出 $\text{Youth}(a)$ ，也即今天是青年节？ (✗)

归结演绎推理示例

现有A,B,C三名学生选择燕园和昌平校区宿舍，规则和协商如下：

- (1) 由于燕园宿舍紧张，至少一名同学入住昌平校区
- (2) 如果 A选择昌平校区 而 B选择燕园校区，则 C选择昌平校区
- (3) 如果 B选择昌平校区，则 C也选择昌平校区

试用归结原理求证：C一定选择昌平校区

归结演绎推理示例

第一步：将问题用谓词公式表示

- 前提：
- (1) 至少一名学生入住昌平校区
 - (2) 如果 A 选择昌平校区 而 B 选择燕园校区, 则 C 选择昌平校区
 - (3) 如果 B 选择昌平校区, 则 C 也选择昌平校区

下面用 A , B , C 分别表示三位学生选择昌平校区, 得到

- (1) $A \vee B \vee C$
- (2) $(A \wedge \neg B) \rightarrow C$
- (3) $B \rightarrow C$

结论：学生 C 一定选择昌平校区

C

归结演绎推理示例

第二步：将谓词公式转化为**子句集**，并将**结论的否定化为子句**，也加入子句集

$$(1) \quad A \vee B \vee C$$

$$(2) \quad (A \wedge \neg B) \rightarrow C$$

$$\Leftrightarrow \neg(A \wedge \neg B) \vee C$$

$$\Leftrightarrow \neg A \vee B \vee C$$

$$(3) \quad B \rightarrow C$$

$$\Leftrightarrow \neg B \vee C$$

$$(4) \quad \neg C$$

子句集： $\{A \vee B \vee C, \neg A \vee B \vee C, \neg B \vee C, \neg C\}$

归结演绎推理示例

第三步：证明子句集是不可满足的

$$(1) \quad A \vee B \vee C$$

$$(2) \quad \neg A \vee B \vee C$$

$$(3) \quad \neg B \vee C$$

$$(4) \quad \neg C$$

$$(5) \quad B \vee C \quad \text{由 (1) (2)}$$

$$(6) \quad C \quad \text{由 (3) (5)}$$

$$(7) \quad \text{矛盾} \quad \text{由 (4) (6)}$$


所以同学 C 一定入住昌平校区

$$(A \vee B \vee C) \wedge (\neg A \vee B \vee C) = (A \vee \neg A) \wedge (B \vee C)$$

知识图谱最新进展




北京大学
PEKING UNIVERSITY




基于预训练语言模型(pretrained Language Model, LM)创建知识图谱

知识图谱最新进展



图神经网络做知识图谱推理


使用**图神经网络** (Graph Neural Network) 学习节点表示, 得到 s, r, o 的表示后, 用神经网络 $f(s, r, o)$ 给出其概率, 进而用于知识图谱补全和推理。




图数据无处不在



社交网络 (微信、微博)



生物网络 (代谢网络、基因网络)




分子图


BEIJING SUBWAY MAP (1983)



城市网络 (交通、安防、基站)




食物链



knowledge graph

知识图谱


- 大小不确定，拓扑结构复杂（不像图片，文本在空间上是结构化的）
- 没有固定的节点顺序或者参考点
- 目标：学习节点的表示，或全图的表示




- 对于一个图 G :
 - V 是**节点的集合**
 - $A \in \{0,1\}^{|V| \times |V|}$ 是**邻接矩阵** ($A_{ij} = 1$ 表示节点 i, j 存在边)
 - $X \in \mathbb{R}^{|V| \times d}$ 为**节点的特征矩阵**
 - v 是 V 中的一个节点; $N(v)$ 是 v 的邻居节点的集合; d 为特征的维度。
 - 节点特征可以是:
 - 在社交网络中: 用户特征, 用户头像
 - 生物网络: 基因表达特征, 基因功能信息
 - 知识图谱: 节点所代表的实体的文本embedding
 - 当没有节点特征时: 可以使用常数或度代替

如何在图上学习

- 最简单的方法是将邻接矩阵和节点特征连接到一起，输入到全连接神经网络。



	A	B	C	D	E	Feat	
A	0	1	1	1	0	1	0
B	1	0	0	1	1	0	0
C	1	0	0	1	0	0	1
D	1	1	1	0	1	1	1
E	0	1	0	1	0	1	0




- 这种做法的问题：
 - $O(|V|)$ 的参数
 - 无法迁移到节点数不同的图
 - 对节点顺序敏感


排列不变

- 使用不同的方式标注节点后，仍要被识别为同一个图。


Order plan 1




Node features X_1




Adjacency matrix A_1




Order plan 2




Node features X_2




Adjacency matrix A_2



参考CNN学习方式




Image



Graph


核心思想： 通过聚合邻居节点的特征学习中心节点表示。

所有节点的邻居构成了一个计算图




INPUT GRAPH

聚合节点邻居
生成中心节点表示



图神经网络(GNN)

一种最简单的实现:





	A	B	C	D	E	Feat
A	0	1	1	1	0	1 0
B	1	0	0	1	1	0 0
C	1	0	0	1	0	0 1
D	1	1	1	0	1	1 1
E	0	1	0	1	0	1 0

1	2
3	1
2	1
2	1
1	1

$$A \cdot X \rightarrow X'$$



or more carefully designed, $(A + I)XW \rightarrow X'$

- GNN的核心任务就是设计不同的消息聚合方式。





多层GNN



- 和CNN一样，GNN也可以堆叠很多层，获得更大的感受野。
- 第一层先聚合邻居节点的原始特征，第二层使用第一层得到的新节点表示作为特征再次做消息聚合。k层图神经网络即可学习到k-hop信息。



- **思想：** 每个节点都会产生一个消息，并提供给其他节点
- **消息函数：** $m_u^{(l)} = MSG^{(l)}(h_u^{(l-1)})$
- **例如：** 线性层 $m_u^{(l)} = W^{(l)} h_u^{(l-1)}$
 - 其中 l 表示第 l 层， $h_u^{(l-1)}$ 表示节点 u 的 $l - 1$ 层表示



- **思想:** 每个节点 v 聚合其邻居的消息。
- **聚合函数:** $h_v^{(l)} = AGG^{(l)}(\{m_u^{(l)}, u \in N(v)\})$
- **例如:** $h_v^{(l)} = sum(\{m_u^{(l)}, u \in N(v)\})$



- **问题:** $\mathbf{h}_v^{(l)}$ 的表示与 $\mathbf{h}_v^{(l-1)}$ 无关
- **解决方式:** 在 $\mathbf{h}_v^{(l)}$ 的计算中使用 $\mathbf{h}_v^{(l-1)}$


- **(1) 计算消息:** 需要计算 v 自身的消息。

- 通常使用不同的消息计算方式

$$\text{●} \text{●} \text{●} \quad \mathbf{m}_u^{(l)} = \mathbf{W}^{(l)} \mathbf{h}_u^{(l-1)} \qquad \text{●} \quad \mathbf{m}_v^{(l)} = \mathbf{B}^{(l)} \mathbf{h}_v^{(l-1)}$$



- **(2) 消息聚合:** 在聚合完邻居消息后, 使用concat(拼接) 或者 summation, 聚合自身的消息:

$$\mathbf{h}_v^{(l)} = \text{CONCAT} \left(\underbrace{\text{AGG} \left(\left\{ \mathbf{m}_u^{(l)}, u \in N(v) \right\} \right)}_{\text{First aggregate from neighbors}}, \underbrace{\mathbf{m}_v^{(l)}} \right)$$



GNN排列不变


- 给定一个节点，改变其排列顺序（编号），通过GNN学习得到的表示是不变的。
- 因为GNN不依赖特定节点顺序，不论什么顺序下一个节点的邻居都是固定的！



图神经网络总结



- GNN通过多层消息传递层学习节点表示
- 最后可以通过一个全局pooling层学习到全图表示



谢谢



北京大学
PEKING UNIVERSITY

